



Offre GenAI By SCC

Déploiement d'une IA Générative



Réf. : SCC-Nom-document-Client-Vx.docx

Avis.

Ce document contient des informations confidentielles appartenant à SCC. Aucune partie de son contenu ne peut être utilisée, copiée, communiquée ou transmise à une partie, de quelque manière que ce soit, sans l'autorisation préalable et écrite de SCC.

© Copyright 2023 – SCC, All Rights Reserved.

Confidentialité.

Ce document est sensible et classifié **TLP-GREEN**

Couleur	Quand classer ainsi ?	Comment l'information peut être partagée ?
TLP:RED Ne pas diffuser, restreint aux seuls habilités. 	TLP:RED doit être utilisé lorsque les informations pourraient avoir des impacts sur le respect d'une réglementation, de la stratégie, de la réputation ou des opérations d'un tiers si elles sont mal utilisées.	Les destinataires ne peuvent pas partager les informations TLP: RED avec des tiers en dehors de l'échange, de la réunion ou de la conversation spécifique dans lequel elles ont été initialement divulguées.
TLP:AMBER Diffusion limitée, Restreint aux organisme habilités. 	TLP:AMBER doit être utilisé lorsque les informations portent un risque d'avoir des impacts sur le respect d'une réglementation, de la réputation ou des opérations d'un tiers si elles sont partagées en dehors des organisations impliquées.	Les destinataires ne peuvent partager les informations TLP:AMBER qu'avec les membres de leur propre organisation et avec les clients qui ont besoin de connaître les informations pour se protéger ou prévenir d'autres dommages.
TLP:GREEN Diffusion limitée, restreint à un groupe identifié. 	TLP: GREEN doit être utilisé lorsque l'information est utile pour la sensibilisation de toutes les organisations participantes ainsi que des pairs au sein de la communauté ou du secteur au sens large.	Les destinataires peuvent partager les informations TLP:GREEN avec des pairs et des organisations partenaires au sein de leur secteur ou de leur communauté, mais pas via des canaux accessibles au public. Les informations de cette catégorie peuvent être largement diffusées au sein d'une communauté particulière mais pas en dehors.
TLP:WHITE Diffusion non limitée. 	TLP : WHITE doit être utilisé lorsque les informations comportent un risque minime ou inexistant d'utilisation abusive, conformément aux règles et procédures applicables en matière de diffusion publique.	Sous réserve des règles de droit d'auteur standard, les informations TLP:WHITE peuvent être distribuées sans restriction.

Acteurs SCC

L'équipe SCC ayant apporté une contribution directe à cette proposition :

Nom	Titre	Rôle	Email
Koceila MEHANI	Solution Architect	Initiateur / Rédacteur	kmehani@fr.scc.com

Historique de révision du document

Date	Révision	Propriétaire	Résumé
Xx/xx/xxxx	1.0	Koceila MEHANI	Première version

Sommaire

1	INTRODUCTION AU DOCUMENT.....	5
2	L'IA GÉNÉRATIVE EN ENTREPRISE.....	8
2.1	SITUATION ACTUELLE.....	8
2.2	UNE PLATEFORME UNIQUE POUR VOUS AIDER À ACTIVER TOUTES LES DONNÉES DANS ET AUTOUR DE VOTRE LAC DE DONNÉES.....	8
2.3	C'EST QUOI LIGHTON ?.....	9
2.4	ARCHITECTURES DE RÉFÉRENCES.....	10
2.4.1	HPE.....	10
2.4.2	Dell.....	12
3	PRESTATIONS DE SERVICES PROPOSÉES.....	13
3.1	INTRODUCTION AUX PRESTATIONS.....	13
3.2	PÉRIMÈTRE DU PROJET ET DES PRESTATIONS.....	15
3.2.1	Architecture cible :.....	16
3.2.2	Préparation amont.....	16
3.2.3	Réalisation d'un POV (Proof of Value).....	16
3.2.4	Intégration d'un cluster dans un environnement de production.....	17
3.2.5	Transfert de compétence auprès du client.....	17
3.2.6	Résultats escomptés ou critères d'acceptation du Prototype.....	19
3.2.7	Livrables des prestations.....	19
3.2.8	Prérequis généraux pour la réalisation du projet :.....	19
3.2.9	Prestations Optionnelles :.....	20
3.2.10	Prestations exclues du périmètre.....	20
3.3	DESCRIPTIF DES PHASES ET TRAVAUX DU PROJET.....	21
3.3.1	Phases, étapes prérequis et livrables.....	21
4	ANNEXE.....	30
4.1	HARDWARE :.....	30
4.1.1	LLM (Paradigm).....	32
4.2	NETWORKING.....	33
4.3	SOFTWARE.....	34
	Helm Chart.....	35

Avant-propos



nous simplifions le complexe.

Le présent document constitue une offre d'IA générative au bénéfice de nos clients, il décrit les prestations de SCC pendant toute la durée d'exécution du contrat et pour l'étendue des services décrits dans le présent document.

Les prestations décrites dans le présent document sont le résultat des échanges entre XXX et SCC, qui ont permis de définir les attentes de XXX et la réponse de SCC pour y répondre.

SCC a des axes résolument innovants, orientés sur un outillage puissant et appartenant aux meilleures technologies du marché (Supervision, ITSM, Contact et Compliance Management) ainsi que sur un réel savoir-faire opérationnel basé sur une expertise avancée des infrastructures de production, du réseau et de la sécurité.

SCC porte également une attention particulière à la gouvernance et à la gestion de ses services, avec pour objectif et vocation d'être un partenaire fiable, durable et flexible qui permet à ses clients de maîtriser leur "stratégie".

Nous pensons que les services que nous offrons sont un véritable moteur de productivité et pas seulement un poste de coût.

Nous travaillons pour chacun de nos clients afin de prendre en compte et de nous adapter aux changements, aux nouveaux besoins et aux évolutions qui pourraient survenir tout au long de ce partenariat, tout en maintenant un principe d'amélioration et de progrès continus pour l'ensemble des services confiés.




1 Introduction au document

ChatGPT, CoPilot, et Gemini sont rapidement devenus des noms familiers dans cette ère de l'IA générative (genAI) en raison de leur accessibilité et de leur facilité d'utilisation. Parallèlement à ces plateformes populaires, nous voyons émerger sur le marché de plus en plus d'outils et d'applications d'entreprise axés sur la genAI. Qu'il s'agisse de la génération de textes et d'images, de la création de vidéos ou même de la génération de voix, les applications d'IA générative existent pour toute une série de cas d'utilisation en entreprise conçus pour stimuler la productivité, l'efficacité et l'automatisation.


L'IA générative devient une technologie incontournable, elle est amenée à changer profondément les processus de nombreux métiers (et a déjà commencé à le faire), est de plus en plus sollicitée par des directions métiers sur l'expérimentation d'approches basées sur l'IA pour résoudre des problématiques métier et/ou pour obtenir des gains de productivité importants.

L'IA générative a enregistré des avancées remarquables en relativement peu de temps, la course à l'innovation a poussé les différents acteurs sur le marché à proposer des modèles plus sécurisés, plus créatifs, moins hallucinants, ...

Parmi ces modèles, nous



L'implémentation d'une IA générative en entreprise peut se faire de plusieurs façons



C'est pourquoi SCC, propose une offre d'IA générative

L'objectif de cette offre est de répondre aux défis actuels des entreprises et proposer un accompagnement de bout en bout sur les initiatives d'IA générative des entreprises sur les différentes couches suivantes :

- Infrastructure permettant d'héberger la solution
 - Design et consolidation de l'infrastructure IA
 - Installation et mise en service
- Orchestrateur : (si besoin)
 - Installation et configuration du cluster kubernetes
- Les modèles et support :
 - Intégration
 - Contextualisation
 - Enrichissement des connaissances du modèle
 - Apporter des résultats pertinents dans un contexte spécifique

SCC propose une Offre de Data virtualisation qui s'adresse aux équipes informatiques (IT, Data) des entreprises nécessitant la modernisation et consolidation de leurs plateformes de données dans un contexte on-premise, cloud, hybrid ou multi-cloud.

Après étude des différents acteurs existants sur le marché, nous avons décidé de travailler avec notre partenaire Starburst qui offre un puissant moteur de requête SQL (basé sur Trino Ex : presto) qui peut être utilisé pour se connecter à différentes sources de données, s'intègre parfaitement avec les outils existants dans beaucoup d'entreprises et propose un très large choix de connecteurs qui nous permettent d'accéder à toute les sources de données de l'entreprise à partir d'un seul endroit.

Le document ci-après est structuré de la manière suivante :

Partie	Titre	Résumé
1	Synthèse de notre proposition	Résumé de notre offre, ses principales caractéristiques, avantages et ses atouts concurrentiels.
3	Descriptif des services et prestations	Dans cette section, nous décrivons les prestations de support proposées, les processus et organisations nécessaires pour en assurer la production.
4	Partie financière	Eléments budgétaires.
5	Annexes	Informations complémentaires, références, documents et données informatives



Section 2

2 L'IA générative en entreprise

2.1 Situation actuelle

Les entreprises d'aujourd'hui sont confrontées à des défis importants lorsqu'il s'agit de gérer leurs entrepôts de données, la complexité architecturale, les silos de données et le besoin d'une source unique de vérité.

Le contexte hybrid, cloud et mutli-cloud est devenu une tendance majeure dans de nombreuses entreprises aujourd'hui. SCC propose une Offre de Data virtualisation qui s'adresse aux équipes informatiques (IT, Data) des entreprises nécessitant la modernisation et consolidation de leurs plateformes de données

Les investissements dans les nouvelles technologies IT sont inévitables pour suivre les exigences du marché et rationaliser les coûts de possession.

L'un des défis les plus courants auxquels sont confrontées les équipes informatiques est la difficulté d'accéder aux données résidant sur de multiples plateformes.

La variété et la nature distribuée des sources de données posent de nouveaux défis en matière de découverte, d'accès et d'activation des données. Les utilisateurs de données doivent souvent attendre que les données soient consolidées dans un entrepôt de données central ou un lac de données avant de pouvoir les utiliser à des fins d'analyse, de data science ou d'exploitation

Cela a des conséquences très réelles allant de la perte de productivité à des ensembles de données incomplets - ce qui conduit à une analyse des tendances plus lente et moins précise. Les responsables informatiques et les chefs d'entreprise recherchent des solutions qui leur permettent d'accéder facilement à des données provenant de sources diverses et de les analyser, ce qui se traduit par un délai plus court pour obtenir des informations et par une réduction du coût total de possession (TCO).

2.2 Une plateforme unique pour vous aider à tirer le meilleur parti de l'IA

Les silos de données ne nécessitent plus de migrations constantes de données, mais plutôt une manière plus systémique de permettre l'accès aux données, quel que soit l'endroit où elles se trouvent dans l'entreprise.

Starburst, le moteur d'analyse des données, fournit un moteur d'analyse rapide et efficace pour l'entrepôt de données, le lac de données. Starburst libère la valeur des données distribuées en les rendant rapides et faciles d'accès, quel que soit l'endroit où elles se trouvent.

Starburst exécute des analyses de lac de données haute performance directement sur le stockage objet et vous aide à choisir le type de données à transférer dans l'entrepôt de données. Parce que les lacs de données modernes peuvent vous offrir des capacités similaires à celles d'un entrepôt, vous n'avez pas besoin de placer toutes vos données dans un seul entrepôt de données.

un entrepôt de données pour centraliser les données pour toutes les analyses, Starburst peut vous aider à réduire le risque de cet investissement et à faire de l'entrepôt un élément d'une stratégie plus large de lac de données moderne.

Les entreprises qui s'associent à Starburst obtiennent des capacités similaires à celles d'un Datawarehouse directement sur le datalake.

100%
future-proof
architecture

53%
lower TCO

90%
faster time
to insight

Starburst vous offre la flexibilité d'exécuter des charges de travail interactives et ETL fédérées à l'aide d'un seul moteur de requête, ce qui réduit considérablement les délais et les coûts de déplacement des données.

2.3 C'est quoi LightOn ?

Starburst est construit sur Trino, le moteur SQL distribué haute performance open-source, qui est connu pour exécuter des requêtes analytiques rapides sur des sources de données dont la taille varie de quelques Go à quelques Po.



Les capacités de Presto se traduisent remarquablement bien sur le stockage objet, et le riche ensemble de fonctionnalités de Trino le place en bonne position pour gagner la bataille prix/performance contre Hadoop et d'autres technologies dans la plupart des cas.

La distribution Starburst Enterprise Platform de Trino a été créée pour aider les entreprises à tirer davantage de valeur de leurs déploiements Trino grâce à une sécurité globale avec des contrôles d'accès précis, des versions stables et fiables, des connecteurs supplémentaires, la mise en cache des données et un support d'entreprise comprenant des conseils de la part du groupe d'experts Trino le plus qualifié au monde.

Pour ces raisons, nous avons choisi de nous associer à Starburst et de fournir à nos clients une référence de conception pour le déploiement de Starburst et de l'adapter de manière appropriée à l'évolution du volume de requêtes, de la concurrence ou du volume de données.

Comment ça marche ?

Les équipes chargées des données peuvent dès à présent tirer parti de notre collaboration. L'annonce d'aujourd'hui permet aux clients de

Déployer rapidement une architecture entièrement testée comprenant du matériel Dell, Starburst Enterprise Platform et d'autres logiciels sur site.

Collaborer efficacement avec les TI pour déplacer les données de façon intelligente dans un lac de données ou un entrepôt de données en fonction des modèles d'utilisation.

Éviter le verrouillage des fournisseurs grâce à la prise en charge des tables ouvertes et des formats de fichiers les plus courants.

Séparez le calcul et le stockage et évoluez de manière flexible et efficace.

Exploitez les innovations de notre dernière génération d'appiances ECS en tant que stockage de lac de données.

2.4 Architectures de références

2.4.1 HPE

HPE Generative IA LLM	5137933577-02	DL380A - 4xL40S
LightOn - RAG	5137845958-04	DL320 - 1xL40S
LightOn - LLM - Basic socle	5137845280-03	DL380A - 2xH100 NVL
LightOn - LLM - Basic socle - Alternative1 [4xH100-32Coeurs-1To]	5137931599-03	DL380A - 4xH100 NVL-32Coeurs-1To
LightOn - LLM - Basic socle - Alternative2 [4xH100-48Coeurs-2To]	5138056601-01	DL380A - 4xH100 NVL-48Coeurs-2To
LightOn - LLM - Basic socle - Alternative3 [4xL40S]	5137931605-02	DL380A - 4xL40S

N.B :

Ces solutions n'intègrent pas les licences des éditeurs logiciel et fera partie du chapitre suivant : à compléter

Dimensionnement : Solution validée pour 1000 utilisateurs déclarés, 300 utilisateurs en simultané.

Il convient de contacter un avant - vente IA pour s'assurer du dimensionnement nécessaire pour le projet du client

Scénario 1 : LLM et Emdedding sur le même serveur

- 1x DL380a Gen11





- 2 cpu Xeon-Gold 6548Y+ 2.5GHz 32-core 250W
- 1,5 TB de ram
- HPE NS204i-u Gen11 NVMe Hot Plug Boot Optimized Storage Device
- 2x disks NVMe 7,68TB High Perf RI
- 1x Mellanox MCX623106AS-CDAT Ethernet 100Gb 2-port QSFP56 Adapter for HPE
- 2x Mellanox MCX631432AS-ADAI Ethernet 10/25Gb 2-port SFP28 OCP3 Adapter for HPE
- ILO 6
- **4x NVIDIA H100 NVL 94GB PCIe Accelerator for HPE**
- 1x HPE 5Y Tech Care Essential with Defective Media Retention Service

Scénario 2 : 2 serveurs : LLM et Emdedding sur deux serveurs différents

Serveur LLM



- **1x DL380a Gen11**
- 2 cpu Xeon-Gold 6548Y+ 2.5GHz 32-core 250W
- 1,5 TB de ram
- HPE NS204i-u Gen11 NVMe Hot Plug Boot Optimized Storage Device
- 2x disks NVMe 7,68TB High Perf RI
- 1x Mellanox MCX623106AS-CDAT Ethernet 100Gb 2-port QSFP56 Adapter for HPE
- 2x Mellanox MCX631432AS-ADAI Ethernet 10/25Gb 2-port SFP28 OCP3 Adapter for HPE
- ILO 6
- **2x NVIDIA H100 NVL 94GB PCIe Accelerator for HPE**
- 1x HPE 5Y Tech Care Essential with Defective Media Retention Service

Serveur Embedding



- **1x DL380a Gen11**
- 2 cpu Xeon-Gold 6548Y+ 2.5GHz 32-core 250W
- 1,5 TB de ram
- HPE NS204i-u Gen11 NVMe Hot Plug Boot Optimized Storage Device
- 2x disks NVMe 7,68TB High Perf RI
- 1x Mellanox MCX623106AS-CDAT Ethernet 100Gb 2-port QSFP56 Adapter for HPE
- 2x Mellanox MCX631432AS-ADAI Ethernet 10/25Gb 2-port SFP28 OCP3 Adapter for HPE
- ILO 6
- **2x NVIDIA L40S 48GB PCIe Accelerator**
- 1x HPE 5Y Tech Care Essential with Defective Media Retention Service

2.4.2 Dell



Section 3

3 Prestations de services proposées

3.1 Introduction aux prestations

Nous allons nous focaliser dans un premier temps sur un

Notre offre prend en compte les phases de projet Design et build du projet qui incluent les prestations de services ci-après :

- Workshop de découverte de cas d'usage
- Choix d'un cas d'usage et aide à la sélection des données à utiliser pour validation de la possibilité de réalisation de ce cas d'usage
- Design et implémentation de l'architecture
- Proof of value d'un cas d'usage pré-sélectionné
- Choix des serveurs
- Commande et mise à disposition du matériel (serveurs, switchs, baies de stockages...etc)
- Commande et mise à disposition du software
- Prototype, validation et passage en production selon des critères définis
- Rédaction du cahier de test et recette
- Transfert de compétence
- Livrables

La nature du projet : ?????

- *Projet planifié sur une durée, ou avant une échéance,*
- *Intervention d'une ressource sans Management de projet particulier*
- *Projet managé, piloté par SCC / Neovision **
- *Piloté par le client (dans ce cas faire une proposition simple d'Assistance Technique en régie)*
- *Indiquez les grands principes retenus :*
 - *Le plan de couverture horaire et journalier des services.*
 - *Ex : Travail la nuit pour une montée de version en prod par exemple*
 - *Les contraintes de délais, de dates ; de lieu, de personnes ;*

- *Les contraintes techniques imposées par le client*

3.2 Périmètre du projet et des prestations

L'offre de prestations SCC porte sur les hypothèses suivantes :

Périmètre :

Nouveau projet : Mise en place d'un cluster d'IA générative avec Lighton

Nombre de Sources : 2 à 3 sources ?

Nombre de serveurs : 1 ou 2

Environnement de déploiement : le déploiement de lighton peut se faire sur plusieurs environnements :

- On premise (Bare-metal ou machines virtuelles)
- Kubernetes (Vanilla, RedHat Openshift, (AKS, EKS, GKE))
- Hébergement chez SCC ou chez un de nos partenaires



Fully managed cloud data lake analytics built and supported by the creators of Trino

Available on leading public clouds



Ce document traite le déploiement de la solution sur un environnement Bare-metal chez le client ou un hébergement chez SCC.

Prérequis :

- Sources de données :
- Accès
- Espace dans le DC


Prestations optionnelles :

- Installation et configuration d'une base de données postgres

- Installation et configuration d'un Hive Metastore

3.2.1 Architecture cible :

L'architecture Paradigm offre une flexibilité totale, pouvant fonctionner sur un seul nœud ou se déployer sur plusieurs, tout en maintenant une communication sécurisée dans un namespace Kubernetes. Elle est agnostique et stateless, ce qui lui permet de s'adapter facilement à tout environnement client, voire de se déplacer d'un environnement à l'autre. Cette solution garantit des performances optimales, une intégration transparente avec Kubernetes, une évolutivité aisée, et répond ainsi efficacement aux besoins évolutifs de votre entreprise.



LightOn offre une gamme diversifiée de solutions d'installation de Paradigm pour répondre de manière précise aux besoins variés de nos clients. Que vous recherchiez une solution clé en main avec la Public SaaS Solution, une confidentialité accrue grâce à la Private SaaS Solution ou encore la Hybrid Private SaaS Solution qui offre la flexibilité d'installer l'application dans le Cloud tout en conservant les données on-premises/privées. La Private Cloud Solution s'intègre harmonieusement dans votre environnement Cloud. De plus, notre option On Premises Solution vous permet de conserver un contrôle total sur votre infrastructure. Quelle que soit la solution choisie, LightOn peut répondre à ces exigences.

3.2.2 Préparation amont

- Indiquez les périmètres géographiques d'intervention des équipes (lieux, salles etc..)

Les prestations permettant de définir les étapes

Passage en revue des cas d'usage possible

Choix le périmètre du POV (les cas d'usages et les nombres de sources à tester et valider...)

Recherche des données utilisables et les sources pour mener à bien le projet

Design de l'architecture Lighton

Validation de la faisabilité du projet avec le client

Définir les critères d'acceptance et rédaction du cahier de test

3.2.3 Réalisation d'un POV (Proof of Value)



La réalisation d'un POV (Proof of Value) peut se faire dans des VMs qui seront approvisionné dans l'infrastructure du client

Prérequis :

3 à 4 VMs avec les caractéristiques suivantes :

A partir de 16 vCPUs et 64 GB RAM (de préférence le double c-à-d 32 vCPUs et 128 GB RAM)

Avoir les accès root

Déploiement des softs ci-dessous :

- Python version 2.6.x, 2.7.x, or 3.x
- Java 17.0.3

Suivant les sources de données (base de données relationnelles, NoSQL, streaming ...), il faudra prévoir les ouvertures de flux (firewall et port) entre le cluster Starburst et les systèmes des sources de données.

Auth

N.B : les versions softwares sont vouées à évoluer dans le temps, donc il est préconisé de vérifier le site web de prérequis pour valider les versions à date.

Lien : <https://docs.starburst.io/latest/installation/deployment.html#requirements>

3.2.4 Intégration d'un cluster dans un environnement de production

L'intégration, l'installation et la configuration d'un cluster en production se déroule en plusieurs phases :

- *Phase 1, Matériels et OS*
 - *Achat des serveurs, licences OS*
 - *Demande des licences de POC pour Starburst*
 - *Livraison du matériel*
 - *Installation du matériel*
- *Phase 2, Paramétrage Starburst*
 - *Mise en place d'une BDD postgresql ou mysql ou oracle*
 - *Installation et configuration d'Apache Ranger*
 - *N.B : l'utilisation des dataproducs nécessite un metastore Hive ou glue*

Lien :

<https://cwiki.apache.org/confluence/display/hive/adminmanual+installation#AdminManualInstallation-InstallingfromaTarball>

- *Quelques exigences sont à prendre en compte notamment la version OS, java runtime, python*
- *Déploiement des packages Starburst sur les serveurs*
Lien pour plus de détails : <https://docs.starburst.io/latest/installation/deployment.html>

3.2.5 Transfert de compétence auprès du client

- *Transfert de compétence au fil de l'installation*
- *Démonstration en fin de configuration*

Rappel : La présente prestation de transfert de compétence ne peut en aucun cas se substituer ou remplacer les formations nécessaires à la maîtrise des technologies proposées par les futurs administrateurs du ou des systèmes installés.



3.2.6 Résultats escomptés ou critères d'acceptation du Prototype

3.2.6.1 Critères de Réception des prestations

*Préciser de manière précise les résultats de la solution (**Warning** dans la mesure du possible, ne jamais s'engager sur des performance Techniques (Débits, vitesse d'Exécution etc..)*

Ex : Les critères de réception de la solution sont :

- *Fin de projet avant le 30 mars*
- *Support technique pendant le déploiement du Lundi au vendredi de 8 à 18 H00*
- *Protocole de tests (à préciser)*
 - *Etat opérationnel de la solution installée*
 - *Applications installées*
 - *Services X, Y, Z démarrés*
 - *Fonctionnalités mises en œuvre et disponibles...*

3.2.7 Livrables des prestations

Les livrables fournis suite aux prestations sont les suivants :

- *Livrables d'études*
 - *Schéma et dossier de configuration de l'infrastructure logicielle retenue*
 - *Scénario et méthode de gestion de projet*
- *Livrables documentaires*
 - *Dossier et schémas d'architecture technique (DAT)*
 - *Cahier de tests et de validation.*
 - *PV de recette*
 - *Matrice de flux (ports...) à jour*
 - *Procédure d'Administration du système*
 - *Compte et mot de passe positionnés*
 - *...*
- *Livrables de gestion du projet*
 - *Comptes rendus de l'étude en amont*
 - *Planning détaillé de la mise en œuvre (ordonnancement des phases et taches)*
 - *Compte rendus de réunion de copil etc..*
 - *Rapport d'avancement projet*
 - *Cahier de test*
 - *PV de recette*

3.2.8 Prérequis généraux pour la réalisation du projet :

Indiquez les prérequis fondamentaux pour la réalisation du projet :

Les pré requis nécessaires à la réalisation des prestations sont :

Ex :

- *Bon de commande de la prestation*
- *Désignation d'un interlocuteur unique (C.P Client) pour la gouvernance conjointe du projet*
- *Les données fondamentales en Imput client pour la connaissance de l'environnement existant*
- *Schéma général d'architecture de l'existant*



- *Liste et identification des contacts par domaine en relation directe avec le projet*
- *Toute opération technique préalable et réalisée par le client ...*
- *Les règles internes de sécurité*
- ..

3.2.9 Prestations Optionnelles :

Plusieurs cas d'usages sont possibles

- L'installation et la mise en place d'une Base de données Postgre ou mysql ou Oracle
- Installation et configuration d'Apache Ranger pour l'authentification
- Connexion d'apache Ranger
- *La mise en place d'un metastore Hive si besoin d'utiliser la fonctionnalité dataproducer*

3.2.10 Prestations exclues du périmètre

Les prestations ci-après sont exclus de l'offre et seront à la charge du client :

- *Le déplacement des données (à la charge du client)*
- *Les ouvertures de flux entre les machines sont à la charge du client*
- *Les opérations de management ou d'administration d'un cloud interne ou externe (GCP, Azure, AWS)*

3.3 Descriptif des phases et travaux du projet

3.3.1 Phases, étapes prérequis et livrables

Le projet de mise en place d'un cluster Starburst sur un environnement bare-metal sur l'infrastructure **du CLIENT** est découpé selon les phases suivantes :

Toutes ces rubriques ne sont pas forcément nécessaires au projet : Indiquez celles qui correspondent au contexte, Supprimez / remplacez les descriptions ou indiquez « Sans Objet »

WP0 : Gestion et Management de projet	Objectif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 0.1 : Lancement et Gestion / Management initial du projet	Réunion destinée à lancer le projet. Dernière mise au point concernant le périmètre, le planning et la commande des prestations Etablir un consensus sur la vision de la proposition SCC • WP 0 : Réunion Plénière animée par SCC	Bon de commande client	Chefs de projet Respectif	?	Compte rendu de Réunion à J+2 Planning Prévisionnel



WP1 : ETUDES : Etudes Architecture et Processus du projet	Objectif /Descriptif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 1.1 : Etude Existant	Collecte des informations existante architecture plan et contraintes actuelles Workshop Animé par SCC •WP 1.1.1 : Workshop étude et prise en compte existant (collecte des données) •WP 1.1.2 : Rédaction Dossier Etude de l'existant et Analyse existant et Remarques (Mise en exergue des contraintes) •WP 1.1.3 : Meeting Présentation Rapport Etude Existant et validation des livrables (le cas échéant)	Equipe Client Disponible pour cette réunion Schémas, adresses IP plan de nommage etc.. D.A.T Client si existant	C.P ou IS SCC	?	Dossier d'étude de l'existant et remarques SCC
WP 1.2 : Etude détaillée Architecture Cible	Collecte des spécifications de l'Architecture cible Design et schéma de la cible à mettre en œuvre •WP 1.2.1 : Workshop collecte des spécifications de l'Architecture cible de Starburst •WP 1.2.2 : Etude détaillée Architecture cible de Starburst (Spécifications de mise en œuvre, Design, gestion des prérequis) •WP 1.2.3 : Rédaction Dossier d'Architecture détaillée (Mise en exergue des alternatives Techniques) •WP 1.2.4 : Meeting Présentation Rapport Etude Architecture détaillée et Validation des livrables	Equipe Client Disponible pour cette réunion Spécifications détaillées en rapport avec le Périmètre	IS ou Architecture SCC	?	Dossier D'Architecture détaillée (Version Alpha)
WP 1.3 : Etude Mise en Œuvre des fonctionnalités	Collecte des spécifications des fonctions à mettre en œuvre et des cas d'usages clients Identifier les données, les sources de données à utiliser •WP 1.3.1 : Workshop collecte des spécifications pour la mise en œuvre des fonctionnalités (Software / Services etc..) •WP 1.3.2 : Etude et spécifications pour la mise en œuvre des fonctionnalités (Services à démarrer / Software à activer etc..) •WP 1.3.3 : Rédaction Dossier de mise en œuvre des fonctionnalités à activer •WP 1.3.4 : Meeting Présentation Rapport Etude des fonctionnalités et Validation des livrables	Equipe Client Disponible pour cette réunion Spécifications détaillées en rapport avec le Périmètre	IS ou Architecture SCC	?	Dossier D'Architecture détaillée (Version Beta)
JALON 1 : Recette Phase d'Etude (remise des livrables d'étude et	Validation de phase d'étude (JL.1) (Go / No Go phases suivante)	Equipe Client Disponible	CP SCC IS ou		Ensemble des Livrables



signature du PV de recette de Phase)		ble pour cette réunion	Expert SCC		Compte Rendu de Réunion
--------------------------------------	--	------------------------	------------	--	-------------------------

WP2 : POV Proof of Value	Objectif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 2.1 : POV (Proof of Value)	Identification et validation du périmètre du POV. Mise à disposition des VMs destinées à réaliser le POV Etablir un consensus sur la vision de la proposition SCC •WP 0 : Réunion Plénière animée par SCC	Bon de commande client	Chefs de projet Respectif	?	Compte rendu de Réunion à J+2 Planning Prévisionnel



WP2/ WP3 : MISE EN ŒUVRE : Installation et configuration HW et SW	Objectif /Descriptif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 2 : Intégration Hardware sur site	Installer et intégrer physiquement les équipements au dans les locaux et au S.I selon le dossier d'architecture ou les indications du client •WP 2.1 : Déballage / Vérification / Installation physique des équipements / Identification étiquetage •WP 2.2 : Intégration HW composant additionnels (Lames /disques / Interfaces HBA etc..) •WP 2.3 : Câblage / Raccordement au Réseau et courant fort •WP 2.4 : Démarrage Power On •WP 2.5 : Vérification des indicateurs de bon fonctionnement (standard constructeur) et Batterie de tests et Validation de Phase	Equipe Client Disponible Identification des lieux et points de connexion Dossier d'Architecture détaillée le cas échéant Indiquez les Prérequis techniques client préalable à l'implémentation Physique -Courant -Espace -réseau -Câblage	Technicien / IS	???	Complétude du dossier et schéma détaillé d'architecture (Chapitre HW et configuration)
JALON 2 : Recette de conformité Installation et configuration Hardware (signature du PV de recette de Phase)	Valider la bonne fin de l'installation HW •JL 2 : Meeting de validation de phase Installation HW (Go / No Go phases suivante) •R.P 2 : Signature du PV de recette Installation Hardware	HW installé Critères : ???	Responsable Client Intervenant ou CP SCC	?	•R.P 2 : Signature du PV de recette Installation Hardware
WP3 : Installation Software et configuration	Installer, activer, configurer les services et les applications selon les spécifications du dossier d'étude (WP1.3) ou le recueil des spécifications client Exemples : •WP 3.1 : Setup et configuration Réseau Lan, Vlan,	Systèmes « ready » Dossier de	Intervenant SCC IS etc..	?	•WP 3.10 : Complétude du dossier et

	Zoning •WP 3.2: Configuration des espaces de stockage (Raid, File system (NAS), Lun's (SAN), Zoning Iscsi, ..) •WP 3.3 : Installation des systèmes (OS natifs) •WP 3.4 : Installation des systèmes de virtualisation (Hyperviseur) •WP 3.5 : Installation des VM •WP 3.6 : Installation d'applications : X,Y (Logiciel d'Administration , Backup etc..) •WP 3.3 : Démarrage et configuration de services (Fonctionnalités ex: Snapshot, répliquions, Clusters ...) •WP 3.8 : Tâches d'Administration des systèmes (Déclaration de ressources / User /droits / Permissions/ Patch, Upgrade Software ...)	configuration et/ou spécifications client			schéma détaillé d'architecture (Chapitre SW et Configuration)
JALON 3 : Recette de conformité Installation et configuration Software (signature du PV de recette de Phase)	•WP 3.9 : Vérification de la conformité de l'installation Software (selon Spécifications du dossier Architecture) ; Batterie de tests et Validation de Phase	Réalisation des travaux ci avant	Responsable Client Intervenant ou CP SCC	?	•R.P 3 : Signature du PV de recette Installation et configuration Software

WP4 : Mise en Œuvre : Installation et configuration de Starburst	Objectif /Descriptif	Pre Requis	Acteur	Charge J/ H Ou Forfait	Livrables
WP 4.1 : Mise au point technique du processus de déploiement de Starburst	Réaliser, paramétrer, tester le processus technique et l'outillage du déploiement de Starburst •WP 4.1.1 : vérification des prérequis de versions java, linux et python •WP 4.1.2 : Téléchargement et mise en place du fichier paquet RPM d'installation et licence Starburst Entreprise •WP 4.1.3 : Construction et mise à jour des fichiers de configurations de Starburst •WP 4.1.4 : Exécution des commandes permettant l'installation de Starburst	•Dossier d'étude de migration ((WP 1.4) le cas échéant	Consultant Starburst	?	•Outils, procédure de configuration de starburst
JALON 4.1: Recette de conformité du Pilote de Migration des données et environnement (signature du PV de recette de Phase)	•JL 4.1 : Meeting de validation de la phase Pilote de migration (Go / No Go phases suivante)	Travaux ci avant	Responsable Client Intervenant ou CP	?	•R.P 4.1 : Signature du PV de recette Pilote



			SCC		de Migrati on
WP4.2 : Migration des données et de l'environnement : Migration proprement dite et bascule en Production	Réaliser la migration des données qui autorise la mise en production de la solution. •WP 4.2.1 : Gestion des prérequis à la migration des données (arrêt de production le cas échéant, arrêt des bases de données, sauvegarde préalable, Plan de Retour Arrière •WP 4.2.2 : Migration des données et de l'environnement selon méthode (la décrire le cas échéant	•Dossier d'étude de migration ((WP 1.4). •Outil de migration et procédures (WP4.1)..	Intervenant SCC	?	•Résultats constatés de la migration
JALON 4.2 : Recette de conformité de la Migration des données et environnement (signature du PV de recette de Phase)	•WP 4.2.3 : Contrôle et Validation de la migration des données et de l'environnement (Check selon grille de Livraison de WP4.1)	Réalisation des travaux ci avant	Responsable Client Intervenant ou CP SCC	?	•R.P 4.2 : Signature du PV de recette Pilote de Migration



WP5 : SECURISATION : Prestations de sécurisation de la solution	Objectif /Descriptif	Pre Requis	Acteu r	Ch arg e J/H Ou For fait	Livrable s
WP 5.1 : Conception et mise en Place plan de secours, de continuité ou de reprise d'activité Informatique	Mettre en œuvre les mécanismes de sécurisation de la solution (Ex : Sauvegarde, Snapshot, Réplifications, Plan de secours ; "PRA etc... •WP 5.1 : Conception et mise en Place plan de secours, de continuité ou de reprise d'activité Informatique - WP 5.1.1 : Recueil des spécifications en cas d'incident et validation de la faisabilité - WP 5.1.2 : Mise en place des mécanismes de réplication/ de redondance et de reprise - WP 5.1.3 : Meeting Présentation Préconisations et Validation du scenarii de sécurisation - WP 5.1.4 : Mise en œuvre et Paramétrage de la sécurisation (Réplication, bascule, recouvrement..)	•Dossier d'architecture ((WP 1.2) le cas échéant •Tous les prérequis techniques correspondant au contexte ..	Intervenant SCC		Opérationnalité des mécanismes de sécurisations
JALON 5.1 : Recette de phase de sécurisation (Signature du PV de recette de Phase)	• WP 5.1.5 : Tests des scenarios d'incidents et de reprise des services	Réalisation des travaux ci avant	Responsable Client Intervenant ou CP SCC		• R.P 5.1 : Signature du PV de recette de Phase de sécurisation



WP6 : OPTIMISATION DES SYSTEMES : Prestation d'optimisation des fonctionnalités et de la performance	Objectif /Descriptif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 6.1 : Audit et Analyse du fonctionnement en production	Auditer le système et la solution installée et préconiser et/ou paramétrer le cas échéant pour optimiser les performances en production. •WP 6.1.1 : Audit fonctionnement des systèmes (collecte des données et informations système) •WP 6.1.2 : Analyse et préconisations (Mise en exergue des points d'optimisation) •WP 6.1.3 : Meeting Présentation Préconisations et Validation •WP 6.1.4 : Travaux d'optimisation (Paramétrage, tuning ...) et tests Ressources et estimation de charges (Facultatif pour les charges Reprendre la grille de Calcul le cas échéant)	Toute autre phase du projet validée.	Intervenant SCC (Expert)	?	Constat selon mesure initiale et progrès obtenu. MAJ DAT avec Paramètres positionnés
JALON 6.1 : Recette de phase d'optimisation (Signature du PV de recette de Phase)	• Validation de la phase d'optimisation	Réalisation des travaux ci avant	Responsable Client Intervenant ou CP SCC	?	•R.P 6.1 : Signature du PV de recette de Phase d'optimisation

WP7 : TRANSFERT DE COMPETENCE : Transfert informel de compétence sur site	Objectif /Descriptif	Pre Requis	Acteur	Charge J/H Ou Forfait	Livrables
WP 7.1 : Journée de formation informelle sur site	Transférer de manière informelle la compétence de l'intervenant vers un ou plusieurs interlocuteurs désignés. En cours d'installation ou en fin de phase ou de projet •WP 7.1 : L'Intervenant SCC présente les fonctionnalités les écrans, et montre les principaux mécanismes d'Administration ou d'exploitation des systèmes. Il réagit dans un mode « Questions Réponses »	Interlocuteur client (Admin etc..)	Intervenant SCC	?	N /A

WP0 : Gestion et Management de projet	Objectif /Descriptif	Pre Requis	Acteur	Charge J/H Ou	Livrables
---------------------------------------	----------------------	------------	--------	---------------	-----------



				Forfait	
WP 0.2 : Bilan de Projet	Finaliser la remise des livrables Démontrer la bonne fin des prestations Signer le PV de recette final du projet sur la base des PV de recette intermédiaires	Bonne fin des phases constituant la prestation	Intervenant ou CP SCC	?	Collecte et remise de l'ensemble des livrables et PV de recette
JALON F : Recette et Bilan de projet (remise des livrables et signature du PV de recette de projet)	Le chef de projet et l'intervenant SCC procèdent à la présentation des résultats et livrables en réunion de pilotage du projet. La prestation sera achevée lorsque SCC aura : - Présenté les PV de recette signés lors des étapes successives de mise en œuvre de la solution - Finalisé et remis en main propre les documents livrables du projet.	Recette des phases en Amont	Responsable Client Intervenant ou CP SCC	?	Signature du PV de Recette Projet

4 Annexe

Sizing d'un cluster LightOn:

A date, deux architectures sont possibles, à savoir :

- Architecture non scalable (1 serveurs avec 4GPU H100)
- Architecture scalable (2 serveurs avec 2 GPU H100 et 2 GPU L40s)

Durée POC et mise en production d'un use case :

- POC : On peut rester sur entre 1 et 2 mois et 5 jours temps plein Starburst
- Mise en production d'un premier use case : Entre 2 semaines et plusieurs mois avec entre 5 et 10 jours d'expertise Starburst

4.1 Hardware :

Scénario 1

4xH100 - HPE ProLiant DL380a Gen11 4DW	
Server Summary	
Line Voltage	230 VAC
VA Rating	3053.58 VA
BTU HR	10389.71 BTU/h
System Current	13.28 A
Utilization Input Power	3046.84 W
Idle Input Power	462.9 W
Max Load Input Power	3046.84 W
Weight (kg)	35.96 kg
Weight (lbs)	79.28 lbs
Utilization Carbon Emissions (CO2e)	6798 kg CO2e
Utilization (%)	100%

Scénario 2

2x NVIDIA L40S 48GB - HPE ProLiant DL380a Gen11 4DW	
Server Summary	
Line Voltage	230 VAC
VA Rating	2328.79 VA
BTU HR	7915.3 BTU/h
System Current	10.13 A
Utilization Input Power	2321.2 W
Idle Input Power	310.63 W
Max Load Input Power	2321.2 W
Weight (kg)	35.96 kg
Weight (lbs)	79.28 lbs
Utilization Carbon Emissions (CO2e)	5179 kg CO2e
Utilization (%)	100%

2xH100 - HPE ProLiant DL380a Gen11 4DW	
Server Summary	
Line Voltage	230 VAC
VA Rating	2328.79 VA
BTU HR	7915.3 BTU/h
System Current	10.13 A
Utilization Input Power	2321.2 W
Idle Input Power	363.41 W
Max Load Input Power	2321.2 W
Weight (kg)	35.96 kg
Weight (lbs)	79.28 lbs
Utilization Carbon Emissions (CO2e)	5179 kg CO2e
Utilization (%)	100%

Déploiement de la solution : HPE DL380a Gen11

Le serveur **HPE ProLiant DL380a Gen11** est un serveur doté d'une évolutivité avancée pour les GPU, l'innovation en matière de sécurité et un contrôle simplifié qui peut améliorer les performances des applications gourmandes en ressources graphiques.

Le serveur utilise les processeurs Intel Xeon Scalable de 4e génération et prend en charge jusqu'à 4 GPU à double largeur dans un boîtier dense (format dense 2U 2P). Ce serveur offre des performances exceptionnelles avec plus de cœurs, une mémoire DDR5 plus rapide et une bande passante d'E/S PCIe Gen5 à grande vitesse, tout en permettant aux entreprises d'innover grâce à des solutions avancées de gestion des données, à des accélérateurs GPU avancés sur une architecture ultra-scalable.

Dans cette solution, nous installons les nœuds dédiés à :

- L'inférence et RAG dans le même serveur
- Inférence et RAG dans deux serveurs différents

Expérience intuitive d'exploitation en cloud

- Moderniser la gestion du cycle de vie grâce à la simplicité du cloud
- Unifier la gestion des données avec une console centralisée
- Réduire les efforts manuels et améliorer l'efficacité du support
- Apporter en toute sécurité l'agilité du cloud à l'infrastructure de calcul distribuée

Performances optimisées pour les charges de travail des clients

- Exigez davantage de l'infrastructure.
- Gagnez en liberté pour innover avec des accélérateurs GPU avancés.
- Adoptez une approche ouverte pour les charges de travail exigeantes.

Sécurité de confiance dès la conception

- Tirez parti de l'innovation de pointe en matière de sécurité ; la sécurité fait partie de l'ADN de HPE.




- Étendre la meilleure protection de sécurité de sa catégorie à l'écosystème des partenaires, y compris les périphériques PCIe.
- Construisez une infrastructure protégée avec la sécurité élargie de la chaîne d'approvisionnement de HPE.




4.1.1 LLM (Paradigm)

Version H100



RAG ou Embedding :



4.2 Networking

Nombre maximal d'utilisateurs simultanés

Pour 300 utilisateurs simultanés 95% des réponses obtenues en moins de 20 secondes

Avec deux GPUs dédiés de type H100, c'est-à-dire la configuration standard recommandée pour déployer Paradigm, pour 300 utilisateurs simultanés nous obtenons une latence p95 de 20 secondes. C'est à dire qu'avec 300 utilisateurs simultanément connectés sur Paradigm et faisant des requêtes au LLM à un rythme naturel, 95% des réponses sont obtenues en moins de 20 secondes. Autrement dit le temps entre l'envoi de la requête par l'utilisateur et la fin de l'affichage complet de la réponse (incluant l'affichage progressif du texte) est de moins de 20 secondes dans 95% des cas.

Un temps de réponse médian de 2 secondes

Dans cette même configuration (2 GPUs H100, 300 utilisateurs simultanés), 50% des réponses sont fournies par le LLM en moins de 2 secondes (latence p50 de 2 secondes).

Impact sur le dimensionnement de l'infrastructure

Ces chiffres sont à prendre comme point de repère pour dimensionner l'infrastructure nécessaire au déploiement de Paradigm dans votre entreprise. Avec plus de GPUs et moins d'utilisateurs simultanés Paradigm sera plus rapide, et inversement avec moins de GPUs et plus d'utilisateurs simultanés, la latence sera plus élevée.

Q : Les drivers CUDA sont-ils compatibles entre les cartes A40, A100, H100 et L40 ?

R : Non, pour les cartes H100 et L40, un driver plus récent est nécessaire par rapport à celui utilisé pour les A40 et A100. Assurez-vous de mettre à jour les drivers pour une compatibilité optimale.

La gestion de la mémoire se fait de manière spécifique selon les besoins de chaque carte. Deux cartes sont utilisées pour le modèle de langage et une autre pour l'embedding. Chaque carte consomme la mémoire nécessaire pour les poids du modèle, pour l'inférence, ainsi que pour la mise en cache afin d'accélérer l'inférence. Normalement, les utilisateurs n'ont pas à se préoccuper de cet aspect.

Il est essentiel que les deux cartes utilisées pour faire tourner le modèle de langage soient sur le même nœud, idéalement connectées via NVLink. La carte dédiée à l'embedding peut être située sur un autre nœud, et dans ce cas, une connexion réseau standard (comme Ethernet) est suffisante.

PowerSwitch S5248F-ON ou équivalent

Le PowerSwitch S5248F-ON comprend les dernières solutions matérielles et logicielles désagrégées de Dell pour les réseaux de centres de données, offrant des ports 25/100GbE de pointe à haute densité et une large gamme de fonctionnalités pour répondre aux exigences croissantes de l'environnement des centres de données d'aujourd'hui.



4.3 Software

outil	version	présentation
LightOn		
Paradigm	Version:1.0 Licence: Apache 2.0	Application principale réalisée en Django. Points de terminaison d'API, points de terminaison de flux de travail Builder, points de terminaison de tableau de bord, frontend et panneau d'administration.
LLM-Serving	Version:1.0 Licence : Apache 2.0	Moteur d'inférence et de service pour les LLM
Embeddings	Version:1.0 Licence: Apache 2.0	Moteur d'inférence et de service pour les modèles d'intégration
Open Source		

Celery	Version:1.0 Licence: BSD 3-Clause "New" or "Revised" License	Un framework de queue de tâches asynchrones distribuées pour Python. Distribuer des tâches asynchrones telles que la journalisation aux travailleurs, afin de ne pas exécuter de code coûteux en calcul sur le serveur web.
Redis	Version:7.0 Licence: BSD 3-Clause "New" or "Revised" License	Une base de données très rapide, basée sur des paires clé-valeur. Cache et backend pour Celery pour stocker les queues de tâches.
Postgres	Version:15.0 Licence:PostgreSQL License	Base de données SQL performante, scalable et ouverte. Base de données principale, pour persister les utilisateurs, les clés d'API, les permissions, les rôles, les journaux, les modèles d'invite, les évaluations...
ChromaDB (déprécié)	Version :0.4.24	ChromaDB, une base de données rapide, évolutive et optimisée pour les opérations analytiques. ChromaDB est conçue pour gérer de grandes quantités de données analytiques, offrant des performances élevées pour les requêtes complexes et les opérations de traitement des données. Elle est idéale pour les environnements nécessitant un traitement rapide des requêtes et une analyse détaillée des données
Weaviate	Version:1.24.1 Licence: BSD 3-Clause "New" or "Revised" License	Weaviate, une base de données de connaissances vectorielles conçue pour le machine learning et les fonctionnalités de recherche sémantique. Weaviate est spécialement conçue pour faciliter l'intégration et la recherche de grandes quantités de données grâce à des modèles de langage vectoriels. Elle offre des performances exceptionnelles pour les requêtes sémantiques et le clustering de données, rendant les environnements de recherche et d'analyse de données plus intuitifs et efficaces.
Grobid	Version : 0.8 Licence: Apache 2.0	Grobid, un outil robuste et précis pour l'extraction et l'analyse de données bibliographiques et métadonnées de documents PDF. Grobid est conçu pour traiter efficacement des volumes élevés de documents, offrant des capacités avancées d'extraction de texte et de métadonnées. Cet outil est particulièrement adapté aux environnements nécessitant une conversion rapide et précise de documents PDF en données structurées pour des analyses poussées.
Helm Chart		

NGINX	Version : 4.6.0	Nginx est un serveur web haute performance et un serveur proxy inverse. Nginx en tant que reverse proxy dans un cluster Kubernetes gère la répartition du trafic entrant entre les pods du cluster, améliorant ainsi la disponibilité, la sécurité et les performances des applications.
Cert manager	Version : 1.11.1	Le cert-manager est un contrôleur Kubernetes qui automatise la gestion et le renouvellement des certificats SSL/TLS Le cert-manager simplifie la gestion automatique des certificats SSL/TLS pour sécuriser les applications web déployées dans un cluster Kubernetes.
Infrastructure et drivers		
kubernetes	Version : 1.26.X < Version < 1.27.X	Kubernetes est un système d'orchestration de conteneurs open-source pour automatiser le déploiement, la mise à l'échelle et la gestion des applications conteneurisées. Kubernetes facilite la gestion de la charge de travail et des services nécessaires pour faire fonctionner une application, tout en optimisant l'utilisation du matériel sous-jacent.
Cuda	Version : 12.2	CUDA est une plateforme de calcul parallèle et un modèle de programmation inventé par NVIDIA. Elle permet d'accroître considérablement les performances de calcul en exploitant la puissance des unités de traitement graphique (GPU). Utilisée pour les tâches de calcul intensif, CUDA est essentielle dans les domaines de la science des données, de l'ingénierie et de la recherche, où des calculs rapides et efficaces sont nécessaires.
Nvidia Driver	Version : > 525	Les pilotes Nvidia sont des composants essentiels qui permettent aux cartes graphiques Nvidia de communiquer efficacement avec les systèmes d'exploitation et d'exploiter pleinement leur capacité graphique. Ces pilotes sont régulièrement mis à jour pour améliorer les performances, corriger les bugs et ajouter de nouvelles fonctionnalités pour une expérience utilisateur optimale.
Django	Version : 3.2 < Version < 4.0 Licence: BSD 3-Clause "New" or "Revised" License	Django est un framework web open-source de haut niveau en Python qui encourage le développement rapide et une conception pragmatique et propre. Django facilite la création de sites web complexes en offrant un ensemble complet d'outils intégrés pour la gestion des bases de données, la validation des formulaires, l'authentification des utilisateurs, les modèles de données, et bien plus encore. Son architecture repose sur le principe "Don't Repeat Yourself" (DRY), permettant aux développeurs de réutiliser le code et de réduire la duplication.

4.4 Procédure de déploiement pour Paradigm


Paradigm : **Paradigm**, spécialement conçu pour les entreprises, concrétise la vision d'une IA intégrée en combinant l'ensemble de la chaîne de valeur de l'IA générative

Paradigm : est déployable dans l'infrastructure de votre choix, garantissant flexibilité et sécurité.



PARADIGM Deployment Process

Lighton





Étape 1 : Préparation des Images Docker

- création des fichiers Dockerfile pour chaque service requis par l'application Paradigm.

Étape 2 : Construction de l'Image Docker

- Utilisation des Dockerfile pour construire les images Docker correspondantes. Ces images contiendront les environnements et dépendances nécessaires pour exécuter les services de Paradigm.

Étape 3 : Scripting et Versioning

- Préparation des scripts Python nécessaires pour le déploiement (indiqués par des fichiers `pythonfile.py`).
- Versionning des scripts et des configurations associées à l'aide de Git pour le suivi et la maintenance.

Étape 4 : Configuration de l'Infrastructure

- Configuration de l'infrastructure sous-jacente, qui comprend les clusters et les nœuds Kubernetes, les espaces de noms (namespaces) et la base de données (BDD).

Étape 5 : Déploiement dans l'Environnement Kubernetes

- Déploiement des configurations (manifestes Kubernetes, fichiers de configuration KOTS) dans l'environnement Kubernetes.

Étape 6 : Validation de l'Environnement

- Inspection de l'environnement pour s'assurer que toutes les instances de services, y compris l'API et les modèles LLM, sont opérationnelles et accessibles dans l'espace de noms dédié.

Étape 7 : Accès à l'Application

- Une fois que tout est configuré et déployé, accédez à l'application Paradigm via l'interface utilisateur pour commencer à utiliser les services de l'application.

Débit :

Le tableau ci-dessous présente à titre indicatif les données de performance lorsqu'un client d'inférence local est alimenté en requêtes à un rythme infini (pas de délai entre les messages), et montre le débit du scénario client-serveur sous une charge maximale.

Les données de performance ci-dessous ont été recueillies en suivant les étapes décrites dans le présent document.

Toutes les données du tableau ci-dessous ont été générées avec la version 0.11.0 et présentent le débit des jetons en jetons/seconde.



Acronyme :

Acronyme	Signification
RAG	Retrieved Augmented generation